Classification d'images sur CIFAR-10 par réseaux de neurones convolutionnels : structuration des données, apprentissage et interprétation du modèle

1st Santiago Florido Gomez
Ingénieur Degree Programme STIC
ENSTA Paris
Paris, France
santiago.florido@ensta.fr

2nd Javier Andres Tarazona Jimenez
Ingénieur Degree Programme STIC
ENSTA Paris
Paris, France
javier-andres.tarazona@ensta.fr

3rd José Daniel Chacón Gómez
Ingénieur Degree Programme STIC
ENSTA Paris
Paris, France
jose-daniel.chacon@ensta.fr

***Abstract*—Ce rapport étudie la classification supervisée d'images de CIFAR-10 par réseaux de neurones convolutionnels. L'analyse couvre d'abord la structuration des données, la standardisation des images et la définition d'une architecture de référence, puis l'étude de la dynamique d'apprentissage à travers l'effet de la taille du batch et du choix d'optimiseur. Un inventaire raisonné des hyperparamètres du modèle, de l'optimisation et du protocole est ensuite établi. Le modèle est alors approfondi par une architecture convolutionnelle plus profonde, évaluée sous protocole contrôlé au moyen de courbes d'apprentissage, de métriques de validation et de matrices de confusion. Le phénomène de sur-apprentissage est ensuite identifié sur les courbes de coût et analysé sous l'effet de mécanismes de régularisation. Enfin, des cartes d'activation de la première couche et de couches profondes sont visualisées, ainsi que leur évolution au cours de l'entraînement, afin d'interpréter la hiérarchie de représentations apprises par le CNN.**

***Index Terms*—Classification d'images, CIFAR-10, réseaux de neurones convolutionnels, apprentissage supervisé, hyperparamètres, sur-apprentissage, régularisation, cartes d'activation.**

I. Convolutional neural networks et CIFAR-10

Dans le contexte de la classification d'images, les réseaux de neurones convolutionnels se sont consolidés comme l'une des architectures les plus adaptées à l'analyse des données visuelles, car ils permettent l'extraction automatique de caractéristiques spatiales hiérarchiques à partir des données d'entrée. Un réseau neuronal implémenté peut être modélisé comme une application composée

$$f_\theta : \mathbb{R}^{H\times W\times C} \to \mathbb{R}^K, \tag{1}$$

où H et W sont la hauteur et la largeur de l'image, C est le nombre de canaux, K est le nombre de classes et θ désigne l'ensemble des paramètres entraînables.

Cette architecture remplace la connexion dense d'un réseau totalement connecté par une structure à champs réceptifs locaux, partage de poids et extraction hiérarchique de caractéristiques. Une CNN est organisée en plusieurs étapes, et chaque étape contient essentiellement une couche de filtres, une non-linéarité et une opération de réduction ou de *pooling* sur des cartes de caractéristiques [2].

Soit $a^{(0)} = x$ l'entrée. Dans une couche convolutionnelle l, si l'entrée possède C_{l-1} cartes et la sortie possède C_l cartes, l'opération peut s'écrire

$$z^{(l)}_{i,j,m} = b^{(l)}_m + \sum_{c=1}^{C_{l-1}} \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} K^{(l)}_{u,v,c,m}\, a^{(l-1)}_{i+u,\, j+v,\, c}, \tag{2}$$

et, après la convolution, une non-linéarité ponctuelle est appliquée :

$$a^{(l)}_{i,j,m} = \phi\Big(z^{(l)}_{i,j,m}\Big). \tag{3}$$

La dimension spatiale de la sortie d'une convolution avec pas (*stride*) s et remplissage (*padding*) p est donnée par

$$H_l = \left\lfloor \frac{H_{l-1} + 2p_h - k_h}{s_h} \right\rfloor + 1, \qquad W_l = \left\lfloor \frac{W_{l-1} + 2p_w - k_w}{s_w} \right\rfloor + 1. \tag{4}$$

Cela permet de contrôler la résolution spatiale à mesure que le signal traverse le réseau.

Si un réseau possède plusieurs couches, le champ réceptif effectif d'un neurone dans les couches profondes croît avec la profondeur. Une manière utile de le modéliser est donnée par la récurrence

$$R_1 = k_1, \qquad R_l = R_{l-1} + (k_l - 1)\prod_{t=1}^{l-1} s_t, \tag{5}$$

où R_l est la taille du champ réceptif effectif dans la couche l.

L'un des principaux avantages quantitatifs de la convolution est son efficacité paramétrique. Si une couche convolutionnelle possède C_{in} canaux d'entrée, C_{out} canaux de sortie et des filtres de taille $k_h \times k_w$, alors le nombre de paramètres est

$$N^{\text{conv}}_{\text{params}} = (k_h k_w C_{\text{in}} + 1)\, C_{\text{out}}. \tag{6}$$

En revanche, une couche dense reliant une entrée de taille n_{in} à une sortie de taille n_{out} possède

$$N^{\text{fc}}_{\text{params}} = (n_{\text{in}} + 1)\, n_{\text{out}}. \tag{7}$$

Cette différence constitue un élément significatif dans la classification automatique d'images, puisqu'une image d'entrée peut contenir des milliers de variables, tandis que

la convolution exploite leurs caractéristiques structurelles en évitant une croissance explosive du nombre de poids.

Dans l'étape finale de classification, la représentation obtenue par les couches convolutionnelles est aplatie ou agrégée globalement afin de produire un vecteur $h \in \mathbb{R}^d$. Ensuite, une couche affine calcule

$$z = Wh + b, \qquad z \in \mathbb{R}^K, \tag{8}$$

et la probabilité estimée pour la classe k est obtenue au moyen de la fonction *softmax* :

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}. \tag{9}$$

[2]

Il est proposé d'utiliser la base de données CIFAR-10, largement employée dans l'évaluation des algorithmes de classification d'images, qui contient $60\,000$ images RGB de 32×32 pixels réparties en 10 classes, avec $6\,000$ images par classe. La partition standard comprend $50\,000$ images pour l'entraînement et $10\,000$ pour le test ; de plus, l'ensemble de test contient exactement $1\,000$ images par classe et l'ensemble d'entraînement en contient $5\,000$ par classe. Les classes sont *airplane*, *automobile*, *bird*, *cat*, *deer*, *dog*, *frog*, *horse*, *ship* et *truck* [3], ce qui représente un scénario adéquat pour l'analyse des éléments fondamentaux de l'apprentissage profond avec des exigences computationnelles modérées.

Comme une partie de l'objectif de recherche consiste également à étudier de manière contrôlée l'influence de la préparation des données, de la définition de l'architecture, de la sélection des hyperparamètres et de la définition de la dynamique d'apprentissage sur la performance idéale du modèle implémenté, ce cadre expérimental se révèle particulièrement pertinent.

II. Structuration des données

A. *training, validation, test*

La division de la base de données constitue un élément méthodologique propre à l'apprentissage supervisé, de manière à isoler l'information destinée à l'ajustement des paramètres, à la sélection du modèle et à l'évaluation du modèle entraîné. L'ensemble d'entraînement est utilisé pour l'estimation des paramètres du réseau, l'ensemble de validation a pour objectif de mesurer la généralisation du modèle sans intervenir directement dans les actualisations des paramètres, et, enfin, l'ensemble de test sert à obtenir une estimation indépendante et non biaisée de la performance du modèle sur des données qu'il n'a pas vues.

L'objectif de cette séparation est d'éviter la fuite d'information, qui peut se produire lorsque les données d'évaluation du modèle ont été utilisées dans l'estimation des paramètres et dans la définition de celui-ci, afin de pouvoir disposer de véritables mesures de la capacité de généralisation du modèle entraîné.

B. *fonction standardize*

La fonction `standardize` peut être comprise comme une standardisation spatiale réalisée image par image et canal par canal. Pour un ensemble d'images représenté par un tenseur $x \in \mathbb{R}^{N \times H \times W \times C}$, la fonction calcule, pour chaque image n et pour chaque canal c, la moyenne $\mu_{n,c}$ et l'écart-type $\sigma_{n,c}$ sur les dimensions spatiales (H, W), puis transforme chaque pixel selon l'expression (10) :

$$x'_{n,i,j,c} = \frac{x_{n,i,j,c} - \mu_{n,c}}{\sigma_{n,c}}. \tag{10}$$

L'implication de cette implémentation est que chaque canal de chaque image est recentré autour de zéro et redimensionné de sorte que la dispersion soit aussi proche que possible d'une dispersion unitaire. Cet effet d'homogénéisation de l'entrée, en termes de son échelle numérique, facilite le processus d'optimisation et peut être utile pour accroître la stabilité de l'entraînement, car, en réduisant les différences globales d'intensité et de contraste entre les images, la standardisation diminue la variabilité non informative mais présente dans les données d'entrée, de manière à favoriser l'apprentissage par le réseau des motifs structurels les plus pertinents.

III. Architecture du réseau

Dans cette architecture, on définit un réseau de neurones convolutionnel séquentiel composé d'une étape d'extraction de caractéristiques locales au moyen de la convolution, suivie de réductions dimensionnelles par *max pooling*. La couche d'entrée est définie pour un tenseur d'entrée $32 \times 32 \times 3$, où 32 est la hauteur, 32 la largeur et 3 le nombre de canaux de couleur (R, G, B). Cette couche n'apprend pas de paramètres ; elle fixe uniquement la forme attendue des données d'entrée du modèle [6].

Ensuite, une première couche convolutionnelle est définie pour la première extraction des caractéristiques. La couche apprend 8 filtres distincts, ce qui implique qu'à sa sortie elle aura 8 cartes de caractéristiques. Une dimension de noyau $(3, 3)$ est définie, et l'argument `padding="same"` est incorporé dans la définition, ce qui permet de préserver la résolution spatiale de l'image, de sorte que la sortie conserve une hauteur et une largeur égales à celles de l'entrée. Par conséquent, la sortie de cette couche a la taille

$$32 \times 32 \times 8. \tag{11}$$

Une couche de *dropout* est ajoutée, laquelle remplit la fonction de mécanisme de régularisation durant l'entraînement en annulant aléatoirement une fraction des activations des entrées. Néanmoins, puisque la valeur du *dropout* est fixée par défaut à zéro, la couche ne modifie ni l'information ni la dimension du tenseur. Sa sortie demeure

$$32 \times 32 \times 8. \tag{12}$$

On ajoute une couche de *max pooling* qui a un *pool size* $(2, 2)$, ce qui implique qu'elle réduit la résolution spatiale en

prenant la valeur maximale dans chaque fenêtre locale 2×2. De cette manière, la sortie de cette couche est

$$16 \times 16 \times 8. \tag{13}$$

On ajoute ensuite une couche qui convertit le vecteur tridimensionnel en un vecteur unidimensionnel de dimension

$$16 \cdot 16 \cdot 8 = 2048, \tag{14}$$

puis une transformation *fully connected* est implémentée au moyen d'une couche dense vers un espace latent de 64 neurones :

$$\mathbf{h} = \mathrm{ReLU}(W\mathbf{x} + \mathbf{b}). \tag{15}$$

De sorte que la sortie de cette couche est de taille 64, on ajoute une deuxième couche de *dropout* dans laquelle le *rate* est fixé à 0, pour finalement inclure une couche dense supplémentaire vers un espace latent de dimension 10. Dans cette occasion, l'activation *softmax* transforme les scores en une distribution de probabilité :

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^{10} e^{z_j}}, \qquad k = 1, \ldots, 10. \tag{16}$$

Par conséquent, chaque composante de la sortie appartient à l'intervalle $[0, 1]$ et la somme de toutes est égale à 1. La classe prédite est celle associée à l'indice ayant la probabilité la plus élevée :

$$\hat{c} = \arg\max_k \hat{y}_k. \tag{17}$$

Enfin, il y a une dernière couche de *dropout* avec un taux égal à 0.

Les paramètres entraînables sont ceux que le modèle met à jour durant l'entraînement au moyen de la rétropropagation et de l'optimisation, lesquels, dans le cas de la structure proposée, sont incorporés dans les couches convolutionnelles et denses, puisque des couches telles que `Input`, `Dropout`, `MaxPooling2D` et `Flatten` n'incorporent pas de paramètres entraînables dans leur définition. Dans le cas de la couche `Conv2D`,

$$N_{\text{params}} = (k_h \cdot k_w \cdot C_{\text{in}} + 1) \cdot C_{\text{out}}, \tag{18}$$

où k_h et k_w sont les dimensions du filtre, C_{in} le nombre de canaux d'entrée, et C_{out} le nombre de filtres de sortie. Ici,

$$k_h = 3, \qquad k_w = 3, \qquad C_{\text{in}} = 3, \qquad C_{\text{out}} = 8. \tag{19}$$

Alors,

$$N_{\text{params}} = (3 \cdot 3 \cdot 3 + 1) \cdot 8 = (27 + 1) \cdot 8 = 224. \tag{20}$$

C'est-à-dire que cette couche possède 224 paramètres entraînables, y compris le biais [4].

Pour sa part, dans la couche dense avec biais,

$$N_{\text{params}} = (n_{\text{in}} + 1) \cdot n_{\text{out}}, \tag{21}$$

où n_{in} est le nombre d'entrées et n_{out} le nombre de neurones de sortie. Dans le cas de la structure proposée, on a deux couches denses :

$$N_{\text{params}} = (2048 + 1) \cdot 64 = 2049 \cdot 64 = 131136, \tag{22}$$

et

$$N_{\text{params}} = (64 + 1) \cdot 10 = 650. \tag{23}$$

Ainsi, le nombre total de paramètres entraînables est

$$224 + 131136 + 650 = 132010. \tag{24}$$

IV. Apprentissage

A. Définitions : epoch, step, batch

Conformément au cours, l'apprentissage supervisé du CNN de la Section III consiste à ajuster un ensemble de poids entraînables

$$W = \{w_{ij}\}, \tag{25}$$

sur l'ensemble d'apprentissage $A = \{(X_i, V_i)\}_{i=1}^{N}$, de manière à minimiser la loss empirique

$$\begin{aligned} L_A(W) &= \frac{1}{N} \sum_{i=1}^{N} L(\mathrm{ForwardProp}(W, X_i), V_i)\,, \\ \widehat{W} &= \arg\min_W L_A(W). \end{aligned} \tag{26}$$

Lorsque A est partitionné en lots $A_b \subset A$, $|A_b| = B$, la loss associée à un lot est définie par

$$L_b(W) = \frac{1}{|A_b|} \sum_{(X_i, V_i) \in A_b} L(\mathrm{ForwardProp}(W, X_i), V_i)\,. \tag{27}$$

Cette normalisation par $|A_b|$ est retenue dans toute la section, car elle permet de comparer des batch sizes différents sans modifier artificiellement l'échelle numérique de la loss ; elle correspond en outre à la convention de réduction `sum_over_batch_size` utilisée dans l'implémentation Keras.

Une itération d'optimisation sur un lot s'écrit alors, pour chaque connexion (i, j),

$$w_{ij}^{(t)} = w_{ij}^{(t-1)} - \epsilon \frac{\partial L_b}{\partial w_{ij}}, \tag{28}$$

où $\epsilon > 0$ désigne le pas d'apprentissage. Dans ce cadre, un *batch* est un sous-ensemble A_b de cardinalité B, un *step* est une mise à jour de la forme (28), et une *epoch* correspond à un parcours complet de la base d'apprentissage. Si N exemples sont traités avec des lots de taille B, le nombre de steps par epoch vaut

$$S(B) = \left\lceil \frac{N}{B} \right\rceil. \tag{29}$$

Le cours distingue alors trois régimes : $B = 1$ correspond au gradient stochastique, $B = N$ au gradient par lots complets, et $1 < B < N$ à l'apprentissage par mini-batches, qui recherche un compromis entre bruit du gradient, coût calculatoire et vitesse de convergence [7], [8].

B. Influence de la taille du batch

a) Protocole expérimental.: La présente section ne redéfinit ni les données ni l'architecture : le découpage des sous-ensembles et la fonction `standardize` sont ceux de la Section II, et le CNN entraîné est celui de la Section III. Seuls les paramètres d'apprentissage sont modifiés pour l'étude des batch sizes et des optimiseurs.

TABLE I
PROTOCOLE EXPÉRIMENTAL DE LA SECTION 4.

Références amont	Section II pour les données et la standardisation ; Section III pour l'architecture
Sous-ensembles utilisés	5000 images d'entraînement, 1000 images de validation ; l'ensemble de test n'intervient pas dans cette section
Graine de partition	42
Graines d'initialisation	42, 314
Comparaison des batch sizes	$B \in \{8, 16, 32, 64, 128\}$, 8 epochs fixes, SGD avec $\epsilon = 10^{-2}$
Comparaison des optimiseurs	$B = 32$, 8 epochs fixes, mêmes poids initiaux pour une même graine
Hyperparamètres optimiseurs	SGD : $\epsilon = 10^{-2}$; SGD+Momentum : $\epsilon = 10^{-2}$, $\beta = 0.9$; Adam : $\epsilon = 10^{-3}$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\eta = 10^{-7}$
Conventions temporelles	temps/step : moyenne des temps mur mesurés sur les lots d'entraînement ; temps/epoch : temps mur d'une epoch incluant la validation

La comparaison de la taille du batch est conduite à nombre d'epochs fixé, et non à nombre de mises à jour fixé. Ce point est essentiel pour l'interprétation : sur 8 epochs, le nombre total d'updates vaut $8S(B)$, soit 5000, 2504, 1256, 632 et 320 pour $B = 8$, 16, 32, 64 et 128. Les différences observées entre batch sizes combinent donc deux effets : la variation de bruit du gradient et la variation du nombre total de mises à jour.

Dans le tableau II, le symbole $m \pm \sigma$ désigne la moyenne empirique m et l'écart-type empirique σ ; pour le temps par step, l'agrégation porte sur l'ensemble des steps mesurés au cours des deux graines et des huit epochs, tandis que pour le temps par epoch elle porte sur l'ensemble des epochs observées. Les courbes de la figure 3 sont les moyennes calculées sur les deux graines.

TABLE II
INFLUENCE DE LA TAILLE DU BATCH SUR LES COÛTS TEMPORELS MOYENS.

Batch size B	Steps/epoch $S(B)$	Temps moyen par step (s)	Temps moyen par epoch (s)
8	625	0.0052 ± 0.0107	3.882 ± 0.460
16	313	0.0079 ± 0.0160	2.959 ± 0.391
32	157	0.0117 ± 0.0234	2.234 ± 0.410
64	79	0.0182 ± 0.0287	1.745 ± 0.371
128	40	0.0297 ± 0.0383	1.457 ± 0.340

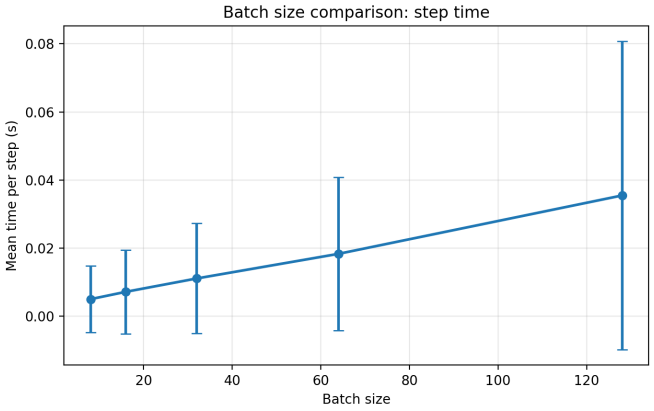

Fig. 1. Temps moyen par step en fonction de la taille du batch.

Les figures 1 et 2 confirment la relation attendue par (29). Le temps moyen par step croît avec B, de $0.0052\,\mathrm{s}$ à $0.0297\,\mathrm{s}$,

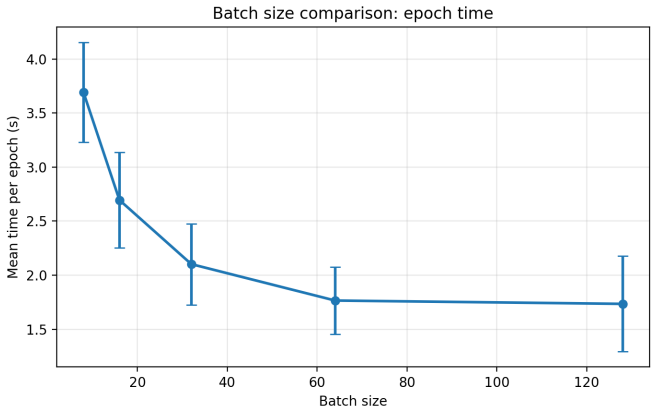

Fig. 2. Temps moyen par epoch en fonction de la taille du batch.

car chaque mise à jour traite davantage d'exemples. En sens inverse, le temps moyen par epoch décroît de $3.882\,\mathrm{s}$ à $1.457\,\mathrm{s}$, puisque le nombre de steps diminue fortement. Cette décroissance reste sous-linéaire, ce qui est cohérent avec le cours : l'augmentation de la taille du lot réduit le nombre d'updates mais n'annule pas le surcoût de calcul de chaque update [7], [8].

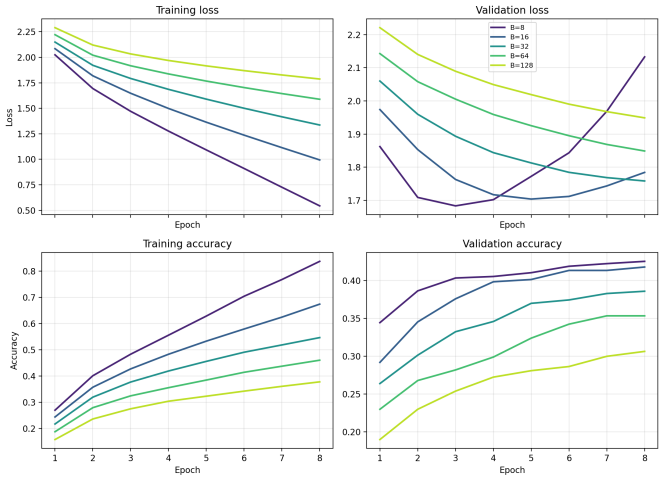

Fig. 3. Courbes moyennes d'entraînement et de validation pour différentes tailles de batch.

L'interprétation des courbes doit rester liée au budget fixé en epochs. Dans ce cadre, les plus petits batches atteignent les meilleures accuracies de validation finales : 42.55% pour $B = 8$ et 41.80% pour $B = 16$, contre 38.60%, 35.35% et 30.65% pour $B = 32$, 64 et 128. Une partie de cet avantage provient du fait que les petits batches réalisent un nombre nettement plus grand de mises à jour sur le même budget de 8 epochs. En revanche, $B = 8$ produit aussi la dynamique de validation la plus bruitée : la val. loss atteint un minimum moyen de 1.6833 à l'epoch 3, puis remonte jusqu'à 2.1329 à l'epoch 8. Sous le protocole considéré, $B = 16$ apparaît ainsi comme la valeur la plus équilibrée parmi celles testées,

en conservant une accuracy finale proche de $B = 8$ avec des courbes de validation moins irrégulières et un temps par epoch plus faible.

C. Comparaison des méthodes d'optimisation

Le SGD de base correspond directement à l'actualisation scalaire (28), appliquée à chaque connexion (i, j). Le cours présente ensuite le SGD avec Momentum sous la forme d'une accumulation des gradients successifs ; pour chaque poids w_{ij},

$$G_t = \beta G_{t-1} + (1-\beta)\frac{\partial L_b}{\partial w_{ij}}, \qquad w_{ij}^{(t)} = w_{ij}^{(t-1)} - \epsilon G_t. \quad (30)$$

Le terme G_t lisse ainsi les variations de direction du gradient d'un batch au suivant [7], [8].

Pour Adam, la présente section reprend explicitement l'écriture simplifiée du cours, sans correction de biais :

$$G_t = \beta_1 G_{t-1} + (1-\beta_1)\frac{\partial L_b}{\partial w_{ij}}, \quad (31)$$

$$K_t = \beta_2 K_{t-1} + (1-\beta_2)\left(\frac{\partial L_b}{\partial w_{ij}}\right)^2, \quad (32)$$

$$w_{ij}^{(t)} = w_{ij}^{(t-1)} - \epsilon\,\frac{G_t}{\sqrt{K_t}+\eta}. \quad (33)$$

Dans cette expression, ϵ désigne le pas d'apprentissage, tandis que $\eta > 0$ est le petit terme introduit au dénominateur pour èviter une division par zéro. Cette méthode adapte donc, pour chaque poids, l'amplitude de la mise à jour tout en lissant les fluctuations temporelles du gradient.

La comparaison des optimiseurs est menée à batch size fixé $B = 32$ et à nombre d'epochs fixé (8). Le tableau III regroupe les statistiques agrégées sur les deux graines ; pour le temps par epoch, la notation $m \pm \sigma$ correspond à la moyenne et à l'écart-type empiriques sur l'ensemble des epochs mesurées, tandis que l'accuracy finale de validation et le minimum de val. loss sont moyennés sur les deux graines.

TABLE III
COMPARAISON DES OPTIMISEURS À BATCH SIZE FIXÉ $B = 32$. LE SYMBOLE $\pm$ DÉSIGNE L'ÉCART-TYPE EMPIRIQUE DU TEMPS PAR EPOCH.

Optimiseur	Temps moyen par epoch (s)	Accuracy finale de validation (%)	Minimum de la val. loss
SGD	2.133 $\pm$ 0.334	38.60	1.7584
SGD+Momentum	2.240 $\pm$ 0.493	40.20	1.7079
Adam	2.417 $\pm$ 0.755	43.45	1.6083

Sous ce protocole, le SGD fournit la décroissance de validation la plus régulière : la val. loss baisse presque monotoniquement jusqu'à 1.7584, pour une accuracy finale de 38.60%. Le Momentum accélère la descente initiale, avec un minimum moyen de val. loss à 1.7079 dès l'epoch 2, mais la remontée ultérieure jusqu'à 2.6743 à l'epoch 8 indique une dégradation plus marquée en fin d'entraînement. Cette observation est cohérente avec l'interprétation du cours : le terme G_t stabilise les directions du gradient, mais peut aussi prolonger des mises à jour devenues trop agressives lorsque ϵ reste fixé.

Parmi les trois optimiseurs testés, Adam obtient les meilleures métriques de validation dans le cadre présent :

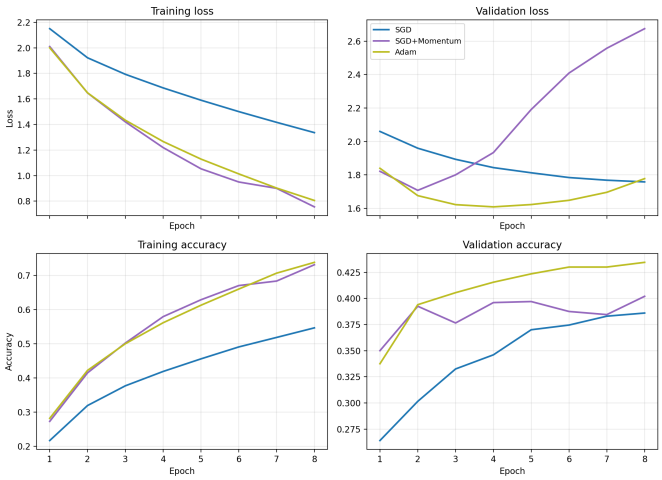

Fig. 4. Courbes moyennes d'entraînement et de validation pour SGD, SGD+Momentum et Adam.

accuracy finale moyenne de 43.45% et minimum moyen de val. loss de 1.6083. Le surcoût temporel reste modéré ($2.417\,\mathrm{s}$ par epoch contre $2.133\,\mathrm{s}$ pour SGD), ce qui suggère que l'adaptation locale des mises à jour compense efficacement cette surcharge sur le budget calculatoire considéré.

D. Synthèse

Sous le protocole à nombre d'epochs fixé retenu ici, la taille du batch agit simultanément sur le bruit du gradient et sur le nombre total de mises à jour. Les petits batches favorisent donc la performance de validation, mais au prix de courbes plus bruitées et d'un temps par epoch plus élevé ; parmi les valeurs testées, $B = 16$ fournit le compromis le plus favorable entre coût temporel et qualité de validation, tandis que $B = 8$ donne l'accuracy finale la plus élevée.

a) Limites expérimentales.: La portée de ces conclusions reste limitée au protocole étudié : sous-ensemble réduit de CIFAR-10, CNN de taille modeste, apprentissage sur CPU et deux graines d'initialisation seulement. Dans ce cadre, Adam présente les meilleures métriques de validation parmi les optimiseurs comparés, avec un surcoût temporel modéré ; cette observation ne prétend toutefois pas valoir indépendamment de l'architecture, du budget d'updates ou du choix des hyperparamètres.

V. HYPERPARAMÈTRES

A. Définition et distinction avec les paramètres entraînables

Contrairement aux poids du réseau, détaillés à la Section III, les hyperparamètres ne sont pas appris par rétropropagation. Ils sont fixés avant ou autour de l'apprentissage et déterminent l'architecture, la fonction objective, le schéma d'optimisation, le protocole d'entraînement et la régularisation [8], [7]. Les poids $W = \{w_{ij}\}$ et les biais des couches convolutionnelles et denses sont, au contraire, ajustés pendant l'optimisation selon les èquations de la Section 4.

Les quantités de journalisation et de sauvegarde, telles que `verbose`, `filepath` ou les options de

`ModelCheckpoint`, sont donc exclues de l'inventaire. Les tailles de sous-ensembles, les graines et le prétraitement `standardize` influencent l'expérience, mais ils sont traités ici comme des conditions expérimentales externes et non comme des hyperparamètres du modèle au sens strict.

B. Inventaire analytique des hyperparamètres

L'inventaire est ètabli directement à partir des appels du notebook et de la pipeline reproductible, en relevant explicitement des expressions telles que `Conv2D(filters=8, kernel_size=(3,3), padding="same")`, `units` (Dense cachée), `compile(loss="categorical_crossentropy", optimizer=...)` et `fit(..., batch_size=..., epochs=..., shuffle=True)`. Pour gagner en précision, les hyperparamètres sont distingués entre hyperparamètres structurels imposés par la tâche, hyperparamètres ajustables de conception, hyperparamètres d'entraînement et hyperparamètres de régularisation.

Les tailles de sous-ensembles, les graines de partition ou d'initialisation et le prétraitement `standardize` ne figurent pas dans les Tables IV et V. Ces quantités modifient bien les conditions d'observation et la variance des résultats, mais elles ne constituent pas des hyperparamètres sintonisables du modèle lui-même.

C. Influence des principaux hyperparamètres sur l'apprentissage

a) Hyperparamètres d'optimisation.: Les hyperparamètres d'optimisation ont déjà fait l'objet d'une ètude empirique en Section 4 ; ils sont seulement replacés ici dans une typologie générale. Dans (28), le pas d'apprentissage ϵ multiplie directement le gradient. Un ϵ trop grand peut donc provoquer des oscillations ou faire franchir une zone de minimum ; un ϵ trop faible ralentit au contraire la convergence et augmente le coût calculatoire. Le choix de l'optimiseur modifie ensuite la manière dont cette actualisation est lissée ou repondérée : le Momentum introduit une inertie directionnelle, tandis qu'Adam adapte localement l'amplitude des mises à jour. La taille du batch, le nombre d'epochs et `shuffle` gouvernent enfin le bruit du gradient, le budget d'actualisations et les effets d'ordre entre mini-batches.

b) Hyperparamètres d'architecture.: Les hyperparamètres d'architecture déjà décrits en Section III deviennent ici des quantités de conception ajustables. Augmenter le nombre de filtres ou la dimension de la couche dense accroît la capacité de représentation du réseau, mais aussi le nombre de poids à estimer. Le noyau convolutionnel et le *pooling* contrôlent en outre le champ récepteur effectif des neurones profonds : via (5), ils déterminent la portion du contexte spatial initial que les dernières couches peuvent analyser pour prendre une décision. Un champ récepteur trop petit limite l'accès au contexte global, alors qu'un champ plus large favorise l'intégration spatiale au prix d'un coût calculatoire et paramétrique plus èlevé.

c) Hyperparamètres de régularisation.: Le dropout et la pénalisation L^2 doivent être analysés même lorsque leurs valeurs sont nulles dans le code. Un taux de dropout strictement positif force le réseau à ne pas dépendre d'un petit nombre de neurones particuliers, ce qui limite la co-adaptation et réduit le risque de sur-apprentissage. La pénalisation L^2, ou *weight decay*, décourage les poids trop grands et tend à lisser le modèle. Ces deux quantités sont donc bien des hyperparamètres de régularisation au sens du modèle, mais elles ne participent pas aux résultats observés dans le protocole courant puisque leurs valeurs sont nulles.

D. Synthèse

La Section V relève les hyperparamètres du projet un par un, avec leur nom exact dans le code, leur nature et leur influence attendue. Les hyperparamètres structurels imposés par la tâche doivent être distingués des hyperparamètres ajustables de conception, d'entraînement et de régularisation. Les tailles de sous-ensembles, les graines et le prétraitement conditionnent l'expérience, mais ils relèvent de conditions expérimentales externes plutôt que d'hyperparamètres du modèle lui-même.

VI. Approfondissement du modèle

A. Limites du modèle de base et objectif du raffinement

Le modèle de base décrit en Section III repose sur une seule couche convolutionnelle suivie d'un *flattening* et d'une tête dense. Cette structure reste valide pour une première étude, mais elle présente trois limites nettes pour la classification sur CIFAR-10. D'abord, l'extraction de caractéristiques demeure peu hiérarchique, puisqu'une seule convolution est appliquée avant la décision. Ensuite, l'essentiel des paramètres entraînables est concentré dans la partie dense : sur 132010 paramètres, 131786 appartiennent à la tête dense, contre seulement 224 pour la couche convolutionnelle. Enfin, aucune régularisation effective n'intervient dans cette baseline, puisque les taux de *dropout* et les coefficients L^2 sont nuls.

Les architectures convolutionnelles sont pourtant motivées, dans le cadre du cours, par l'idée d'une extraction locale et invariante par translation au moyen d'un banc de filtres, combinée à des mécanismes de réduction spatiale par *pooling* ou *stride* [7], [8], [2]. L'approfondissement du réseau doit donc permettre à la fois dáugmenter le champ récepteur effectif, de construire des représentations plus abstraites et de rééquilibrer la répartition des paramètres entre la partie convolutionnelle et la partie décisionnelle. L'objectif de cette section consiste ainsi à concevoir une architecture plus profonde, à en vérifier la cohérence dimensionnelle, puis à mesurer rigoureusement si le gain de performance justifie la complexité supplémentaire.

B. Conception d'une architecture convolutionnelle plus profonde

Le raffinement a été mené à partir de trois variantes plus profondes que la baseline. La première, notée $M1$, ajoute une deuxième étape convolutionnelle et porte la profondeur à quatre convolutions. La deuxième, notée $M2$, ajoute une troisième étape convolutionnelle, ce qui porte la profondeur

TABLE IV
INVENTAIRE DÉTAILLÉ DES HYPERPARAMÈTRES STRUCTURELS, DE CONCEPTION ET DE RÉGULARISATION.

Nom dans le code	Nature précise	Valeur retenue	Influence attendue
`shape`	structurel imposé par la tâche	$32 \times 32 \times 3$	fixe la forme des données d'entrée et contraint la première couche du réseau
`units` (sortie)	structurel imposé par la tâche	10 sorties	impose la dimension de sortie du classifieur, donc le nombre de classes traitées
nombre de couches `Conv2D`	ajustable de conception	1 couche convolutionnelle	fixe la profondeur de l'extraction locale et contribue à la croissance du champ récepteur effectif
`filters`	ajustable de conception	8	modifie la largeur de la représentation convolutionnelle et le nombre de poids appris
`kernel_size`	ajustable de conception	$(3, 3)$	contrôle le voisinage local exploré et participe directement au champ récepteur
`padding`	ajustable de conception	`same`	préserve la résolution spatiale et conditionne la taille des tenseurs transmis aux couches suivantes
`pool_size`	ajustable de conception	$(2, 2)$	réduit la résolution spatiale, le coût calculatoire et agrandit le champ récepteur effectif des couches profondes
`Flatten`	ajustable de conception	`Flatten`	fixe la transition convolution/dense et donc la taille d'entrée de la tête de classification
`units` (Dense cachée)	ajustable de conception	64 neurones	contrôle la largeur de la tête dense et la capacité expressive de la partie pleinement connectée
`activation` (cachée)	ajustable de conception	ReLU	introduit la non-linéarité et limite en pratique l'atténuation du gradient dans les premières couches
`activation` (sortie)	ajustable de conception	softmax	rend la sortie compatible avec une interprétation probabiliste et avec l'entropie croisée
`rate`	régularisation	0.0	si le taux ètait strictement positif, il réduirait la co-adaptation des neurones ; ici son effet empirique est nul
`l2`	régularisation	$\lambda_{L^2} = 0.00$	si le coefficient ètait positif, il pénaliserait les poids trop grands ; ici son effet empirique est nul

TABLE V
INVENTAIRE DÉTAILLÉ DES HYPERPARAMÈTRES D'ENTRAÎNEMENT.

Nom dans le code	Nature précise	Valeur initiale	Valeurs explorées / retenues	Influence attendue
`loss`	entraînement	`categorical_crossentropy`	valeur conservée dans tout le protocole	définit la quantité dont le gradient pilote l'apprentissage ; ici elle est adaptée à une sortie softmax et à des labels one-hot
`optimizer`	entraînement	SGD	SGD, SGD+Momentum, Adam	modifie la dynamique de convergence, le lissage des gradients et la sensibilité au pas d'apprentissage
`learning_rate`	entraînement	0.01	0.01 pour SGD/SGD+Momentum ; 0.001 pour Adam	multiplie directement le gradient dans les mises à jour ; trop grand, il destabilise la descente ; trop faible, il ralentit la convergence
`momentum`	entraînement	0.0	0.0 puis 0.9	ajoute une inertie directionnelle qui lisse les fluctuations du gradient entre deux mini-batches
`beta_1`	entraînement	–	0.9 pour Adam	contrôle le lissage du premier moment dans Adam
`beta_2`	entraînement	–	0.999 pour Adam	contrôle le lissage du second moment dans Adam
`epsilon` d'Adam	entraînement	–	10^{-7} pour Adam	stabilise numériquement le dénominateur de l'update d'Adam ; il correspond au terme noté η dans le rapport
`batch_size`	entraînement	32	8 ; puis $\{8, 16, 32, 64, 128\}$; 32 retenu pour l'étude des optimiseurs	agit sur le bruit du gradient, le nombre d'updates par epoch et le compromis entre stabilité et coût calculatoire
`epochs`	entraînement	20	10 ; puis 8 retenu pour les comparaisons contrôlées	fixe le budget d'apprentissage en passages sur la base et conditionne le niveau de convergence atteint
`shuffle`	entraînement	valeur par défaut dans le notebook	`True` dans la pipeline reproductible	limite les effets d'ordre entre epochs et stabilise l'estimation du gradient stochastique

à six convolutions et réduit la résolution finale à 4×4. La troisième, notée $M3$, reprend exactement le squelette de $M2$ mais y ajoute une régularisation explicite : *dropout* de 0.25 après chaque *pooling*, *dropout* de 0.5 avant la couche dense cachée et pénalisation L^2 de coefficient 10^{-4}.

Cette progression respecte l'interprétation du cours : les couches convolutionnelles successives apprennent des *features* de complexité croissante, tandis que les couches de *pooling* réduisent la résolution spatiale et augmentent la portée contextuelle des neurones profonds [8]. Le choix de noyaux 3×3 conservés à toutes les couches maintient un calcul local simple, tandis que la multiplication des étapes convolutionnelles permet dágrandir progressivement le champ récepteur sans introduire de filtres très larges. Le tableau VI résume les variantes comparées.

Deux observations ressortent immédiatement. D'une part, $M1$ possède davantage de paramètres que $M3$, bien qu'il soit moins profond ; cela provient du fait que deux seuls *poolings* laissent une carte finale de taille $8 \times 8 \times 32$, soit un *flattening* de dimension 2048, alors que $M3$ descend à $4 \times 4 \times 64$, soit une dimension 1024 avant la partie dense. D'autre part, $M2$ et $M3$ ont exactement le même nombre de paramètres, puisque *dropout* et pénalisation L^2 n'ajoutent pas de poids entraînables.

C. Cohérence dimensionnelle des tenseurs

La cohérence entre les tenseurs d'entrée et de sortie a été contrôlée explicitement pour toutes les architectures. Si une

TABLE VI
ARCHITECTURES COMPARÉES POUR L'APPROFONDISSEMENT DU MODÈLE.

Modèle	Backbone convolutionnel	Régularisation	Paramètres
$M0$	8/pool	aucune	132010
$M1$	16-16/pool $\rightarrow$ 32-32/pool	aucune	148442
$M2$	16-16/pool $\rightarrow$ 32-32/pool $\rightarrow$ 64-64/pool	aucune	138330
$M3$	16-16/pool $\rightarrow$ 32-32/pool $\rightarrow$ 64-64/pool	dropout $0.25/0.25/0.25$, dropout dense 0.5, $L^2 = 10^{-4}$	138330

couche reçoit un tenseur $H_l \times W_l \times C_l$, alors une convolution 3×3 avec `padding="same"` et pas 1 produit un tenseur $H_l \times W_l \times F_l$, où F_l désigne le nombre de filtres. Un *max pooling* 2×2 de pas 2 produit ensuite un tenseur

$$\frac{H_l}{2} \times \frac{W_l}{2} \times C_l, \tag{34}$$

ce qui impose que les dimensions spatiales restent compatibles avec les réductions successives.

Pour le modèle finalement retenu, la chaîne dimensionnelle s'écrit :

$$\begin{aligned} &32 \times 32 \times 3 \rightarrow 32 \times 32 \times 16 \rightarrow 32 \times 32 \times 16 \rightarrow 16 \times 16 \times 16, \\ &16 \times 16 \times 16 \rightarrow 16 \times 16 \times 32 \rightarrow 16 \times 16 \times 32 \rightarrow 8 \times 8 \times 32, \\ &8 \times 8 \times 32 \rightarrow 8 \times 8 \times 64 \rightarrow 8 \times 8 \times 64 \rightarrow 4 \times 4 \times 64, \\ &4 \times 4 \times 64 \rightarrow 1024 \rightarrow 64 \rightarrow 10. \end{aligned} \tag{35}$$

Le tableau VII reprend cette progression couche par couche. La transition vers la partie dense demeure assurée par un *flattening*, conformément au schéma décrit dans le polycopié pour les tâches de classification à sortie de taille fixe [8].

TABLE VII
COHÉRENCE DIMENSIONNELLE DU MODÈLE RETENU $M3$.

Couche	Sortie	Paramètres
Input	$32 \times 32 \times 3$	0
Conv2D (16)	$32 \times 32 \times 16$	448
Conv2D (16)	$32 \times 32 \times 16$	2320
MaxPool2D	$16 \times 16 \times 16$	0
Conv2D (32)	$16 \times 16 \times 32$	4640
Conv2D (32)	$16 \times 16 \times 32$	9248
MaxPool2D	$8 \times 8 \times 32$	0
Conv2D (64)	$8 \times 8 \times 64$	18496
Conv2D (64)	$8 \times 8 \times 64$	36928
MaxPool2D	$4 \times 4 \times 64$	0
Flatten	1024	0
Dense	64	65600
Dense	10	650

D. Protocole d'entraînement et comparaison contrôlée

La comparaison a conservé exactement le protocole de données de la Section IV : même partition réduite de CIFAR-10 (5000 images d'entraînement, 1000 de validation, 1000 de test), même standardisation image par image et même nombre de classes. Afin d'isoler autant que possible l'effet de l'architecture, l'optimiseur a été fixé à Adam avec $(\epsilon, \beta_1, \beta_2, \eta) = (10^{-3}, 0.9, 0.999, 10^{-7})$, le *batch size* à 32 et le mélange des mini-batches à `True`.

La campagne a été menée en deux étapes. Un *screening* initial a comparé les quatre architectures sur la graine 42 pendant 10 epochs. Les deux meilleures architectures raffinées ont ensuite été soumises à une phase de confirmation, avec les graines 42 et 314 et un budget de 12 epochs. La règle de sélection a été fixée *a priori* : accuracy finale de validation moyenne maximale, puis minimum moyen de *val. loss*, puis temps moyen par epoch.

Le tableau VIII rassemble les résultats. Lors du *screening*, $M3$ obtient la meilleure accuracy finale de validation (48.10%), devant $M1$ (46.20%), $M2$ (43.60%) et la baseline $M0$ (39.50%). L'intérêt de la régularisation apparaît déjà clairement : $M3$ surpasse $M2$ de 4.5 points dáccuracy finale, alors que les deux modèles partagent exactement le même backbone convolutionnel.

La phase de confirmation confirme cette hiérarchie. $M3$ atteint une accuracy finale de validation moyenne de $50.80\% \pm 1.60$, avec un minimum moyen de *val. loss* de 1.4073 ± 0.0663. $M1$ progresse lui aussi par rapport à la baseline, avec $48.55\% \pm 1.55$, mais reste en retrait. Le gain de $M3$ par rapport à $M0$ est de 8.5 points dáccuracy finale de validation, au prix d'un temps moyen par epoch qui passe de $1.256\,\mathrm{s}$ à $3.708\,\mathrm{s}$.

E. Modèle final retenu : architecture, hyperparamètres, courbes et matrices de confusion

Au vu de la phase de confirmation, $M3$ a été retenu comme modèle final. La figure 5 en donne une représentation graphique, et le tableau IX en synthétise les hyperparamètres effectifs. La profondeur convolutionnelle y est portée à six couches, réparties sur trois étapes de largeur croissante $(16, 32, 64)$, avec trois réductions spatiales successives et une tête dense de dimension 64.

Les courbes dápprentissage de la figure 6 correspondent à un run représentatif du modèle final avec la graine 42. Elles montrent une progression régulière de l'accuracy de validation jusquà l'epoch 11, où celle-ci atteint 50.5%, avant un léger recul à 49.2% à l'epoch 12. La *val. loss* suit la même dynamique, avec un minimum à 1.4737 à l'epoch 11, puis une remontée à 1.5332 à l'epoch final. Cette inflexion signale un début de sur-apprentissage, mais n'annule pas l'amélioration globale observée par rapport à la baseline.

Le modèle final atteint sur l'ensemble de test réduit une accuracy de 50.90% et une loss de 1.5058. Les matrices de confusion de la figure 7 montrent que les classes *frog* (83.81%), *automobile* (79.80%) et *truck* (72.13%) sont les mieux reconnues, tandis que *cat* (9.68%), *bird* (23.91%) et *ship* (28.92%) restent fragiles. Les plus fortes confusions hors diagonale concernent notamment *cat* $\rightarrow$ *dog*, *deer* $\rightarrow$ *frog*, ainsi que *ship* $\rightarrow$ *airplane* ou *automobile*. L'approfondissement améliore

TABLE VIII

COMPARAISON DES ARCHITECTURES PENDANT LE *screening* ET LA CONFIRMATION. POUR LA CONFIRMATION, LE SYMBOLE $\pm$ DÉSIGNE L'ÉCART-TYPE EMPIRIQUE SUR LES DEUX GRAINES.

Etape	Modèle	Nb. conv	Paramètres	Accuracy finale val. (%)	Min. val. loss	Temps/epoch (s)
Screening	$M0$	1	132010	39.50	1.6113	1.346
Screening	$M1$	4	148442	46.20	1.6386	2.824
Screening	$M2$	6	138330	43.60	1.6178	3.463
Screening	$M3$	6	138330	48.10	1.5431	3.833
Confirmation	$M0$	1	132010	42.30 ± 1.10	1.6167 ± 0.0055	1.256 ± 0.611
Confirmation	$M1$	4	148442	48.55 ± 1.55	1.5804 ± 0.0582	2.478 ± 0.702
Confirmation	$M3$	6	138330	50.80 ± 1.60	1.4073 ± 0.0663	3.708 ± 1.453

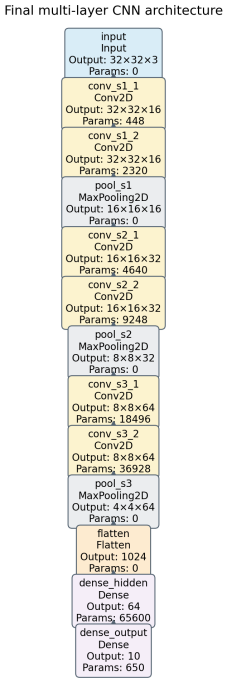

Fig. 5. Représentation graphique du modèle final multi-couches. Le texte interne à la figure est laissé en anglais pour garantir un rendu stable.

TABLE IX

HYPERPARAMÈTRES RETENUS POUR LE MODÈLE FINAL $M3$.

Backbone convolutionnel	16-16/pool $\rightarrow$ 32-32/pool $\rightarrow$ 64-64/pool
Kernel size	$(3, 3)$
Padding	`same`
Pool size	$(2, 2)$
Dense units	64
Dropout après pooling	$0.25/0.25/0.25$
Dropout avant dense	0.5
Pénalisation L^2	10^{-4}
Optimiseur	Adam
Learning rate	10^{-3}
β_1, β_2, η	$0.9, 0.999, 10^{-7}$
Batch size	32
Epochs	12

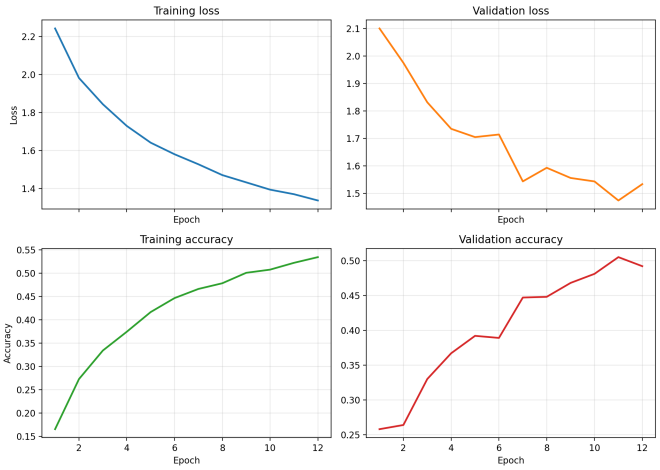

Fig. 6. Courbes dápprentissage du modèle final $M3$ pour le run représentatif de graine 42.

donc la séparation de plusieurs classes, mais il ne supprime pas les ambiguïtés visuelles les plus marquées.

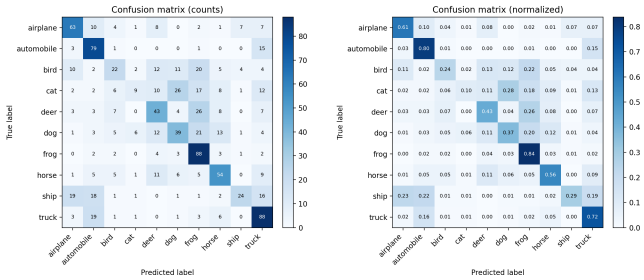

Fig. 7. Matrices de confusion du modèle final : version en effectifs et version normalisée.

F. Discussion critique : avantages et limites

L'approfondissement du réseau apporte un gain mesurable et cohérent avec le cadre théorique du cours. En empilant plusieurs couches convolutionnelles, le modèle retient des caractéristiques plus hiérarchiques et voit son champ récepteur effectif s'agrandir au fil des couches. Cette structuration se traduit ici par une amélioration de l'accuracy de validation de 42.30% à 50.80% entre $M0$ et $M3$, sans explosion du nombre total de paramètres. Le gain ne provient donc pas d'une seule

augmentation massive de la taille du classifieur dense, mais bien d'une meilleure exploitation de la partie convolutionnelle.

La comparaison entre $M2$ et $M3$ montre en outre que la profondeur seule ne suffit pas. À backbone identique, la régularisation explicite de $M3$ améliore nettement la validation et abaisse la *val. loss*. Le *dropout* et la pénalisation L^2 jouent donc ici le rôle attendu : ils limitent la co-adaptation des neurones et contraignent la norme des poids, ce qui devient utile sur un sous-ensemble d'apprentissage aussi restreint.

Les limites du modèle restent néanmoins visibles. D'abord, le coût calculatoire augmente sensiblement : $M3$ exige près de trois fois plus de temps par epoch que la baseline. Ensuite, la performance absolue demeure modérée sur le test réduit, avec 50.90% dáccuracy, ce qui montre que la profondeur ne compense ni la petite taille du corpus déntraînement, ni les ambiguïtés visuelles fortes entre certaines classes. Enfin, les courbes du run représentatif montrent un début de sur-apprentissage en fin déntraînement, ce qui suggère que le budget de 12 epochs reste proche de la limite utile pour cette architecture et ce protocole.

Sous le protocole retenu, l'ajout de profondeur apparaît donc justifié lorsque la priorité est la précision de validation. Le gain de 8.5 points par rapport à la baseline est substantiel, et il s'accompagne d'un meilleur minimum de *val. loss* ainsi que d'une meilleure séparation de plusieurs classes. En revanche, ce raffinement n'a rien d'universel : son intérêt resterait à reconsidérer si la contrainte principale devenait le temps de calcul plutôt que la performance finale.

VII. Sur-apprentissage

A. Identification du sur-apprentissage sur les courbes de coût

Dans le cadre de l'apprentissage supervisé, le sur-apprentissage désigne une situation dans laquelle l'optimisation de la loss empirique sur l'ensemble d'apprentissage se poursuit alors que la qualité de généralisation se dégrade sur l'ensemble de validation. Si l'on note $L_{\text{app}}^{(t)}$ et $L_{\text{val}}^{(t)}$ les coûts observés à l'epoch t sur les ensembles d'apprentissage et de validation, le signe caractéristique du sur-apprentissage est la poursuite de la décroissance de $L_{\text{app}}^{(t)}$ alors que $L_{\text{val}}^{(t)}$ recommence à croître après un minimum. Cette divergence traduit une amélioration de l'ajustement aux données vues sans gain de généralisation sur les données non utilisées pour la mise à jour des poids [7], [8].

Pour quantifier ce phénomène, la présente section retient l'indicateur

$$\Delta_{\text{sur}} = L_{\text{val}}^{(T)} - \min_{1 \le t \le T} L_{\text{val}}^{(t)}, \tag{36}$$

où T désigne l'epoch final du protocole. Une valeur positive de Δ_{sur} indique que la loss de validation finale est supérieure à son meilleur niveau atteint pendant l'apprentissage. Plus cette quantité est grande, plus la dégradation de généralisation en fin d'entraînement est marquée. Le phénomène est d'autant plus probable que la capacité du modèle est élevée, que le corpus d'apprentissage est réduit et que la durée d'entraînement est prolongée sans régularisation explicite [8].

B. Exemple issu du workflow de la Section 6

La Section 6 fournit déjà un exemple exploitable sans introduire de nouvelle architecture. Le *screening* du modèle $M2$ (*three-stage CNN* non régularisé), exécuté avec la graine 42 pendant 10 epochs, présente un comportement de sur-apprentissage net. La figure 8 montre que la loss d'apprentissage décroît presque monotoniquement, de 2.0646 à 0.5822, tandis que la loss de validation atteint un minimum de 1.6178 à l'epoch 4 avant de remonter jusqu'à 2.5590 à l'epoch 10. Il en résulte

$$\Delta_{\text{sur}} = 2.5590 - 1.6178 = 0.9412. \tag{37}$$

Le même diagnostic apparaît sur les accuracies : l'accuracy d'apprentissage finale atteint 78.96%, alors que l'accuracy finale de validation reste à 43.60%, soit un écart de 35.36 points. La meilleure accuracy de validation, 48.20%, est d'ailleurs obtenue avant la fin de l'entraînement. Ce run constitue donc un exemple pertinent pour illustrer la distinction entre optimisation réussie de l'objectif d'apprentissage et dégradation de la généralisation.

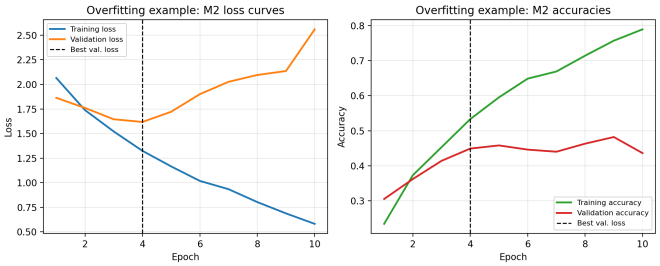

Fig. 8. Exemple de sur-apprentissage réutilisé depuis la Section 6 : modèle $M2$, graine 42, 10 epochs. Le texte interne à la figure est laissé en anglais pour garantir un rendu stable.

C. Effet de mécanismes de régularisation

Afin d'étudier des mécanismes susceptibles de réduire ce phénomène, une campagne contrôlée a été menée sur le même backbone profond que celui de $M2$. Le protocole reste identique à celui de la Section 6 : même split CIFAR-10 réduit ($5000/1000/1000$), même standardisation image par image, Adam avec $(\epsilon, \beta_1, \beta_2, \eta) = (10^{-3}, 0.9, 0.999, 10^{-7})$, *batch size* 32, `shuffle=True`, graines 42 et 314, et budget fixé à 15 epochs. Quatre variantes ont été comparées :

- $R0$: backbone $M2$ sans régularisation explicite ;
- $R1$: backbone $M2$ avec *dropout* (0.25 après chaque *pooling*, 0.5 avant la couche dense) ;
- $R2$: backbone $M2$ avec seule pénalisation L^2 de coefficient 10^{-4} ;
- $R3$: modèle $M3$ de la Section 6, combinant *dropout* et pénalisation L^2.

Ces choix correspondent à deux mécanismes de régularisation explicitement discutés dans le cours. Le *dropout* limite la co-adaptation des neurones en supprimant aléatoirement une partie des activations pendant l'apprentissage, alors que la pénalisation L^2 contraint la norme des poids et décourage des

solutions trop fortement ajustées au corpus d'apprentissage [7], [8]. La figure 9 et le tableau X résument les effets observés.

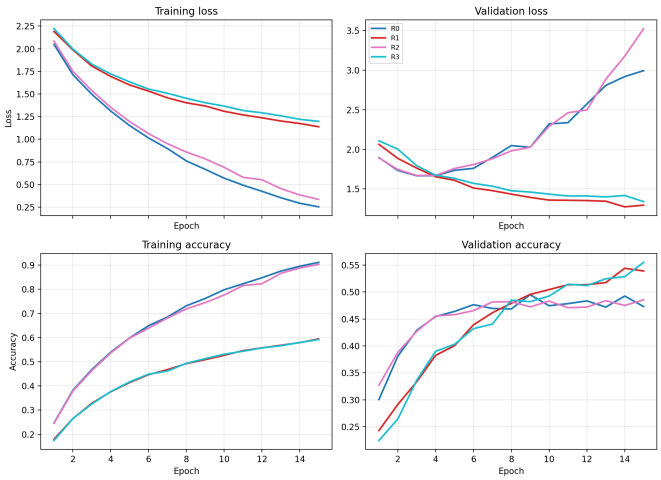

Fig. 9. Comparaison des courbes moyennes d'apprentissage et de validation pour les variantes $R0$ à $R3$. Le texte interne à la figure est laissé en anglais pour garantir un rendu stable.

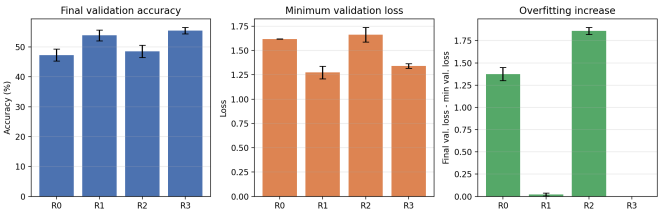

Fig. 10. Synthèse graphique des effets observés sur l'accuracy finale de validation, le minimum de *val. loss* et l'indicateur Δ_{sur}.

Le comportement de $R0$ confirme le diagnostic initial : la loss d'apprentissage continue de décroître jusqu'à 0.2536, alors que la loss de validation remonte jusqu'à 2.9937 après un minimum moyen de 1.6192. L'indicateur moyen $\Delta_{\text{sur}} = 1.3744$ et l'écart final train-val de 43.87 points témoignent d'une généralisation fortement dégradée. L'ajout du seul *dropout* dans $R1$ modifie radicalement cette dynamique : la loss de validation reste presque monotone jusqu'à l'epoch 14, et Δ_{sur} chute à 0.0211. Cette régularisation ralentit l'optimisation sur l'ensemble d'apprentissage, puisque l'accuracy finale train n'est plus que de 59.48%, mais elle améliore nettement la validation, avec 53.90% d'accuracy finale et le meilleur minimum moyen de *val. loss* (1.2743).

La pénalisation L^2 seule, testée dans $R2$, ne produit pas le même effet sous ce protocole. L'accuracy finale de validation, 48.55%, reste proche de $R0$, tandis que Δ_{sur} atteint 1.8604, soit une dégradation encore plus forte que pour la baseline non régularisée. Cette observation indique que, dans ce cadre expérimental, le coefficient 10^{-4} ne suffit pas à contenir le sur-apprentissage du backbone profond lorsqu'il est utilisé sans *dropout*. Enfin, la combinaison des deux mécanismes dans $R3$ donne le meilleur compromis global : l'accuracy finale de validation atteint 55.50%, l'écart train-val tombe à 3.70 points et la loss de validation continue à décroître jusqu'à l'epoch final, ce qui conduit à $\Delta_{\text{sur}} = 0$ sur le budget fixé à 15 epochs.

D. Discussion comparative

Les résultats montrent que la lecture des courbes de coût fournit un critère de diagnostic plus fiable que la seule observation de l'accuracy finale. Dans les variantes non suffisamment régularisées, l'optimisation du coût d'apprentissage se poursuit alors que la loss de validation se dégrade, ce qui signale un apprentissage trop spécifique aux données vues. Ce comportement apparaît très clairement pour $M2$ dans l'exemple issu de la Section 6, puis pour $R0$ et $R2$ dans la comparaison contrôlée.

La comparaison met aussi en évidence que tous les mécanismes de régularisation ne se valent pas dans le protocole retenu. Le *dropout* réduit fortement la co-adaptation et améliore déjà nettement la généralisation lorsqu'il est utilisé seul. La pénalisation L^2 de coefficient 10^{-4}, en revanche, ne suffit pas à elle seule à stabiliser la validation pour ce backbone et ce budget d'entraînement. La combinaison des deux mécanismes fournit finalement le meilleur compromis entre limitation du sur-apprentissage et performance finale, en prolongeant la décroissance de la loss de validation jusqu'à la fin du protocole.

Ces observations restent cohérentes avec la Section 6. L'augmentation de profondeur améliore la capacité de représentation du modèle, mais elle accroît aussi le risque de sur-ajustement sur un sous-ensemble d'apprentissage limité à 5000 images. Dans ce contexte, l'introduction de *dropout* et d'une pénalisation L^2 ne constitue pas un raffinement optionnel, mais une condition importante pour exploiter utilement la capacité supplémentaire du backbone profond. Une stratégie telle que l'*early stopping* pourrait encore être mobilisée pour arrêter l'entraînement au voisinage du minimum de validation, mais elle n'a pas été retenue ici afin de conserver un budget d'epochs identique pour toutes les variantes comparées.

VIII. Cartes d'activation

A. Interprétation des cartes d'activation de la première couche

Pour une image d'entrée X et une couche convolutionnelle l, la carte d'activation du canal m est la réponse spatiale

$$A_m^{(l)}(X) = \phi\Big(z_{:,:,m}^{(l)}(X)\Big)\,, \tag{38}$$

c'est-à-dire la sortie du filtre m après convolution et non-linéarité. Il convient donc de distinguer les filtres appris $K_{u,v,c,m}^{(l)}$, qui constituent les poids adaptables du réseau, des cartes d'activation, qui dépendent à la fois de ces poids et de l'image analysée. Les couches successives composent ainsi une banque de filtres locaux et des transformations non linéaires hiérarchiques, conformément au cadre présenté dans le cours [2], [7], [8].

La présente section réutilise le modèle profond régularisé $M3/R3$ retenu aux Sections 6 et 7. Le run de référence

TABLE X
COMPARAISON DES MÉCANISMES DE RÉGULARISATION SUR LE BACKBONE PROFOND DE LA SECTION 6. LE SYMBOLE $\pm$ DÉSIGNE L'ÉCART-TYPE EMPIRIQUE SUR LES DEUX GRAINES.

Variante	Mécanisme	Accuracy finale val. (%)	Min. val. loss	Δ_{sur}	Écart final train-val (pts)
$R0$	aucune	47.30 ± 2.00	1.6192 ± 0.0014	1.3744 ± 0.0740	43.87 ± 1.37
$R1$	dropout	53.90 ± 1.80	1.2743 ± 0.0636	0.0211 ± 0.0152	5.58 ± 0.34
$R2$	L^2 seul	48.55 ± 2.05	1.6630 ± 0.0763	1.8604 ± 0.0397	41.79 ± 0.13
$R3$	dropout + L^2	55.50 ± 1.10	1.3410 ± 0.0246	0.0000 ± 0.0000	3.70 ± 0.38

correspond à une architecture à trois étages convolutionnels entraînée pendant 15 epochs avec Adam sur le même split CIFAR-10 réduit et la même standardisation image par image ; il atteint 53.70% d'accuracy sur l'ensemble de test, pour une accuracy finale de validation de 53.80% et un maximum de validation de 54.10%. Pour garantir une lecture stable, le rapport retient comme image principale un exemple de la classe *truck*, correctement classé avec une confiance de 0.9933.

La figure 11 présente les 16 cartes produites par la première couche convolutionnelle `conv_s1_1`, de taille $32 \times 32 \times 16$. Plusieurs canaux réagissent nettement aux transitions de luminance entre la carrosserie du camion, l'horizon et la chaussée, tandis que d'autres soulignent davantage les contrastes chromatiques entre le ciel bleu, les zones gris-beige du véhicule et l'arrière-plan. Une mesure objective fondée sur des corrélations avec des proxys simples confirme cette lecture prudente : les canaux 1, 14 et 12 sont les plus corrélés à la norme du gradient, tandis que les canaux 10, 7 et 8 sont les plus sensibles au contraste chromatique. La moyenne du taux d'activations positives vaut 0.464 et l'entropie spatiale normalisée moyenne 0.847, ce qui indique des cartes encore denses et localement interprétables, cohérentes avec un premier niveau de détection de contours, de contraste local et de motifs simples.

B. *Cartes d'activation dans les couches profondes du modèle raffiné*

L'analyse a ensuite porté sur les couches `conv_s2_2` et `conv_s3_2`, qui produisent respectivement des tenseurs de taille $16 \times 16 \times 32$ et $8 \times 8 \times 64$. La réduction progressive de résolution due aux opérations de *pooling*, déjà discutée à la Section 6, augmente le champ récepteur effectif et conduit à des représentations moins directement lisibles à l'échelle du pixel. La figure 12 affiche, pour chaque couche, les 8 canaux de plus forte activation moyenne sur la même image.

Par rapport à la première couche, ces cartes apparaissent plus sélectives et plus parcimonieuses. Le taux moyen d'activations positives passe de 0.422 dans `conv_s2_2` à 0.402 dans `conv_s3_2`, et l'entropie spatiale moyenne diminue de 0.780 à 0.679. Cette évolution est cohérente avec l'idée d'une extraction hiérarchique : certaines cartes intermédiaires restent sensibles à des structures géométriques larges, alors que plusieurs cartes profondes se concentrent davantage sur des zones compatibles avec la silhouette du camion, ses roues ou l'opposition entre l'objet et l'arrière-plan. Une interprétation sémantique directe de chaque canal resterait toutefois excessive, car ces cartes représentent avant tout des réponses internes utiles à la décision de classification.

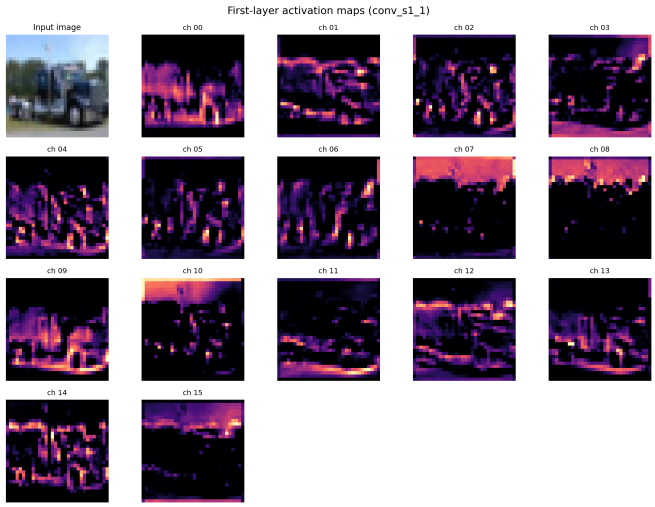

Fig. 11. Cartes d'activation de la première couche `conv_s1_1` pour l'image principale de la classe *truck*. Le texte interne à la figure est laissé en anglais pour garantir un rendu stable.

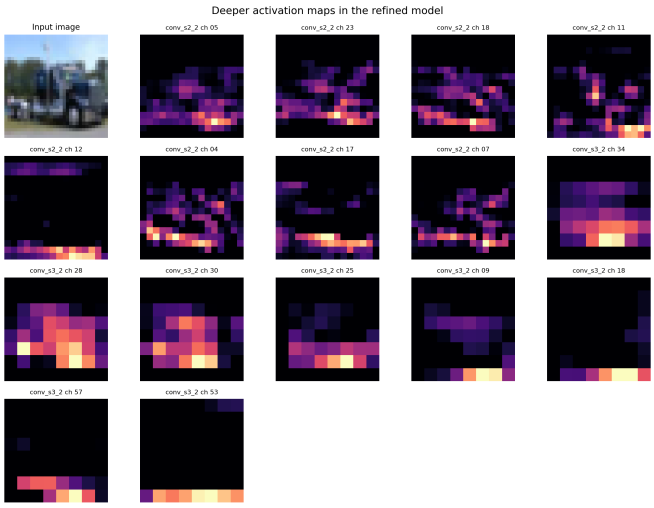

Fig. 12. Cartes d'activation de couches profondes du modèle raffiné : top-8 de `conv_s2_2` et top-8 de `conv_s3_2`, classés par activation moyenne sur l'image principale.

C. Évolution des cartes d'activation pendant l'apprentissage

Aucun checkpoint exploitable n'était disponible pour le modèle profond final avant cette section ; un run de référence a donc été relancé en sauvegardant uniquement les poids aux epochs 0, 1, 5 et 15. La comparaison a été conduite sur la même image principale, avec les mêmes canaux suivis à toutes les étapes : les canaux 12 et 6 de `conv_s1_1`, puis les canaux 34 et 28 de `conv_s3_2`, choisis à partir du modèle final.

La figure 13 montre qu'à l'epoch 0, avant toute mise à jour, les réponses restent diffuses et peu structurées. Dès l'epoch 1, certains contrastes spatiaux deviennent visibles, mais les cartes profondes conservent encore une organisation instable. À l'epoch 5, les structures principales se stabilisent, et à l'epoch 15 les cartes profondes apparaissent nettement plus localisées sur des régions discriminantes. Cette structuration progressive se retrouve dans des statistiques simples : l'écart-type moyen des activations suivies n'augmente que de 0.031 dans `conv_s1_1` entre les epochs 0 et 15, contre 0.303 dans `conv_s3_2`. L'évolution des couches profondes est donc plus marquée que celle de la première couche, ce qui suggère une spécialisation croissante des représentations internes au cours de l'apprentissage.

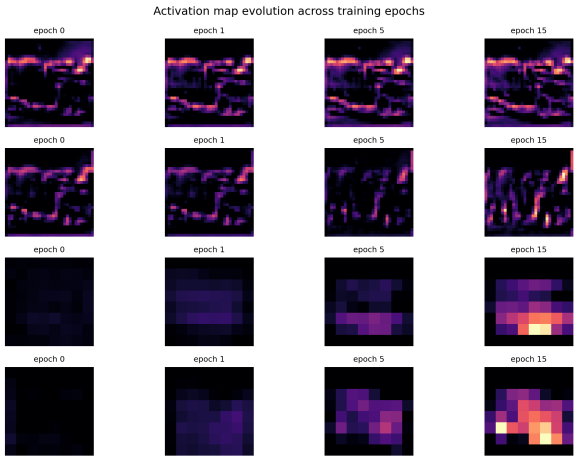

Fig. 13. Évolution des cartes d'activation pour des canaux fixés de `conv_s1_1` et `conv_s3_2` aux epochs 0, 1, 5 et 15. La normalisation est fixée par canal sur l'ensemble des epochs afin de rendre la comparaison temporelle lisible.

D. Discussion et limites d'interprétation

L'ensemble des visualisations reste cohérent avec les choix architecturaux des Sections 6 et 7. Les cartes de la première couche traduisent des réponses locales compatibles avec un banc de filtres sensibles aux bords, au contraste et à certaines oppositions chromatiques, tandis que les couches profondes deviennent plus sélectives à mesure que le champ récepteur effectif s'accroît. L'évolution au cours des epochs montre en outre que les représentations profondes se structurent beaucoup plus fortement que les réponses de bas niveau, ce qui est compatible avec l'apprentissage progressif de motifs utiles à la classification.

Ces cartes ne doivent toutefois pas être sur-interprétées. Les figures reposent sur une normalisation min-max par carte pour les panneaux statiques, puis par canal sur l'ensemble des epochs pour la comparaison temporelle ; elles permettent donc une lecture qualitative, mais pas une comparaison absolue d'amplitude entre tous les canaux. Par ailleurs, une carte d'activation ne fournit pas à elle seule une causalité directe sur la décision finale : elle renseigne sur des réponses internes du réseau, dont une partie seulement peut recevoir une interprétation visuelle explicite. Enfin, le rapport se concentre volontairement sur une image principale pour conserver des figures lisibles ; l'inspection complémentaire d'un exemple correctement classé de la classe *frog* dans le notebook confirme les tendances générales, sans supprimer la part d'ambiguïté inhérente à ce type de visualisation.

References

[1] Keras, "Input object," Keras 3 API documentation, accessed Mar. 8, 2026. [Online]. Available: https://keras.io/api/layers/core_layers/input/

[2] Y. LeCun, K. Kavukcuoglu, and C. Farabet, "Convolutional Networks and Applications in Vision," presented at ISCAS 2010, accessed Mar. 8, 2026. [Online]. Available: https://cseweb.ucsd.edu/~gary/cs200/s12/lecun-iscas-10.pdf

[3] A. Krizhevsky, "CIFAR-10 and CIFAR-100 datasets," accessed Mar. 8, 2026. [Online]. Available: https://www.cs.toronto.edu/~kriz/cifar.html

[4] Keras, "Conv2D layer," Keras 3 API documentation, accessed Mar. 8, 2026. [Online]. Available: https://keras.io/api/layers/convolution_layers/convolution2d/

[5] Keras, "Model training APIs," Keras 3 API documentation, accessed Mar. 8, 2026. [Online]. Available: https://keras.io/api/models/model_training_apis/

[6] Keras, "Input object," Keras 3 API documentation, accessed Mar. 8, 2026. [Online]. Available: https://keras.io/api/layers/core_layers/input/

[7] A. Manzanera, "Classification et apprentissage," support de cours, ENSTA Paris, 2026.

[8] A. Manzanera, "Chapitre 4 – Classification et apprentissage," polycopié de cours, ENSTA Paris, 2026.

TABLE XI
SYNTHÈSE DES VISUALISATIONS RETENUES POUR L'ANALYSE DES CARTES D'ACTIVATION.

Analyse	Couches inspectées	Image retenue	Epochs	Observation concise
Première couche	`conv_s1_1`	*truck*, idx. 626	15	16 cartes encore denses et localement interprétables ; plusieurs canaux soulignent bords et contrastes chromatiques.
Couches profondes	`conv_s2_2`, `conv_s3_2`	*truck*, idx. 626	15	Top-8 par couche ; activations plus sélectives et moins entropiques dans `conv_s3_2` que dans `conv_s2_2`.
Évolution temporelle	`conv_s1_1`, `conv_s3_2`	*truck*, idx. 626	$0, 1, 5, 15$	Mêmes canaux suivis à toutes les étapes ; réponses de plus en plus structurées, surtout dans la couche profonde.